只占 **CPU** 容量 **15.1%** 的会话，在第 **5** 个干扰请求后消失

Qwen3-8B · GPU 511 可用块 · CPU 1695 块（4 GB）· 每个干扰请求 6000 tokens

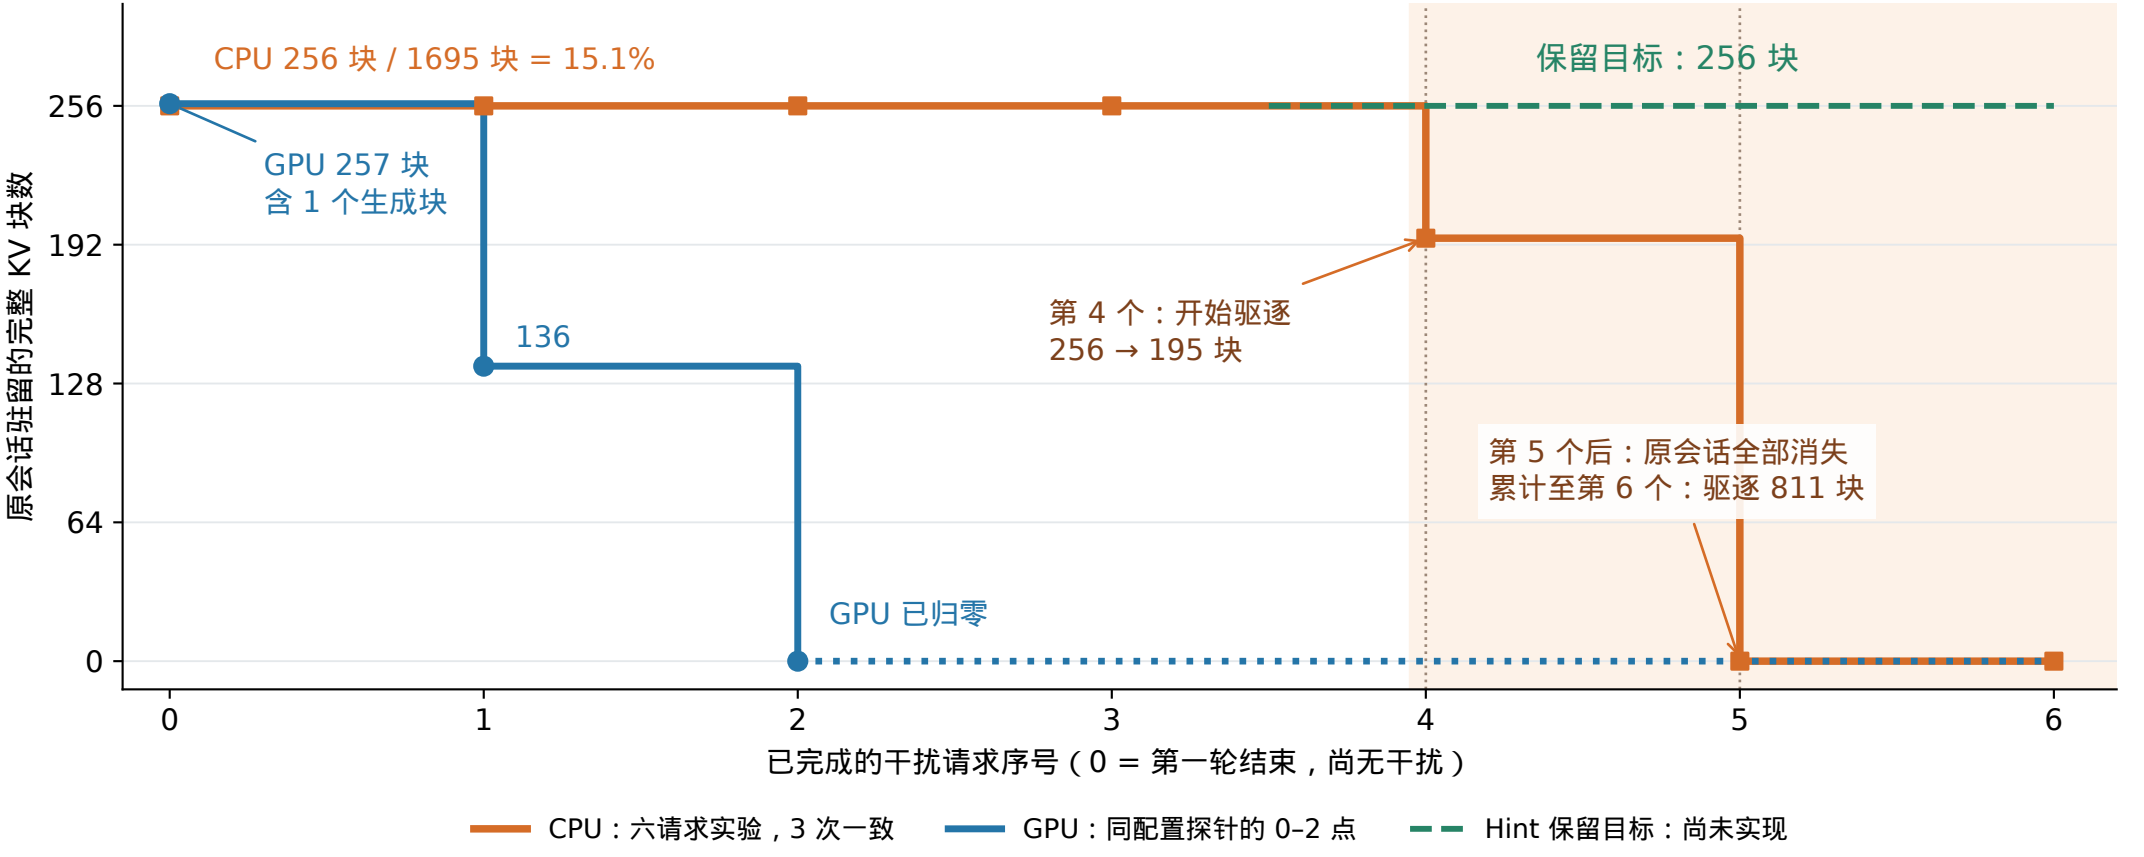

实测第二轮 TTFT：CPU 保留对照 59.1 ms；CPU 丢失对照 121.2 ms（各 3 次中位数）。

GPU 的 0–2 点来自同输入、同容量探针；3–6 点未再访问原会话，延续 0（点线表示推断）。CPU 0–6 点均为实测。

绿虚线仅表示保留目标；六请求压力下 Hint 策略的 TTFT 尚未实测，59.1 ms 是 CPU 保留对照的参照值。